Dakar Institute of Technology (DIT)

Département Data Science & Intelligence Artificielle

Certification en Data Science

RAPPORT DE PROJET FINAL – DEEP LEARNIN

Certification data Science cohorte 2

Projet 2 : Classification d'images satellitaires

Approche par CNN, Régularisation et Transfer Learning (Resnet50)

- **Groupe 4*:***

  Cheikh Yakhouba CISSÉ

  Souleymane GUEYE

  Ndeye Fatou NDIAYE

  Ndeye Khady NDIAYE

- Sous l'encadrement de :

  Professeur **Rose Bandolo**

Dataset : *EuroSAT – Images satellitaires RGB (10 classes, 64×64 pixels)*

Introduction

La classification d'images satellitaires est devenue un enjeu majeur dans de nombreux domaines tels que l'urbanisme, la surveillance environnementale et l'agriculture de précision. Grâce à l'avènement du Deep Learning, et plus particulièrement des réseaux de neurones convolutionnels (CNN), il est désormais possible d'automatiser l'identification des types de couverture terrestre avec une précision dépassant souvent l'analyse humaine manuelle.

L'objectif de ce projet est de concevoir, implémenter et optimiser un modèle capable de classifier des images du dataset EuroSAT, composé de vues satellites RGB de 10 catégories de terrain différentes (zones urbaines, forêts, rivières, etc.).

Cette étude suit une démarche incrémentale :

- Établir un modèle de référence (Baseline) pour évaluer les performances initiales.
- Proposer des optimisations architecturales (Régularisation, Batch Normalization) pour améliorer la robustesse du modèle.
- Exploiter le Transfer Learning via le modèle ResNet50 pour comparer l'efficacité d'un réseau pré-entraîné face à une architecture personnalisée.

Par cette approche, nous chercherons à comprendre comment les choix de conception influencent la capacité de généralisation du modèle face aux défis spécifiques de l'imagerie satellite, tels que la faible résolution et les similitudes chromatiques entre classes.

I. Exploration et préparation des données

- **Analyse du dataset :** Le jeu de données EuroSAT contient 27 000 images satellites RGB de taille 64×64 pixels, réparties en 10 classes (Forêt, Rivière, Autoroute, etc.).
- **Répartition :** Les classes sont relativement équilibrées (~2 000 à 3 000 images par classe), ce qui limite les biais initiaux.
- **Stratégie de préparation :**

  – **Normalisation** par remise à l'échelle (Rescaling) pour transformer les valeurs de pixels [0, 255] vers l'intervalle [0, 1]. Justification : cela stabilise l'apprentissage. Les fonctions

d'activation comme la ReLU ou la Softmax se comportent mieux avec de petites valeurs d'entrée, évitant ainsi des gradients trop instables.

– **Ensemble de Validation** — Un ensemble de validation distinct (10 %) est mis en place.

Pourquoi ? Il sert de 'boussole' pendant l'entraînement. Il permet de détecter l'Overfitting (surapprentissage) : si la précision sur le train augmente mais que celle de la validation stagne ou baisse, le modèle apprend par cœur au lieu de généraliser.

– **Justification de la séparation Train/Test** — La séparation du jeu de données en deux ensembles distincts est la règle d'or pour évaluer l'efficacité d'un modèle d'apprentissage automatique.

– **L'ensemble d'Entraînement (Train Set) :**

Rôle : Il sert à l'ajustement des paramètres du modèle (les poids du réseau de neurones). C'est ici que le modèle apprend à associer les caractéristiques visuelles des images satellite (textures, couleurs des pixels) aux étiquettes correspondantes (Forêt, Route, etc.).

Justification : On lui alloue la majorité des données (généralement 80 % ou 90 %) pour garantir que le modèle rencontre suffisamment de diversité d'exemples pour généraliser les formes et ne pas se limiter à quelques cas particuliers.

– **L'ensemble de Test (Test Set) :**

Rôle : Il sert d'évaluation finale "en aveugle". Le modèle n'a jamais accès à ces données durant sa phase d'apprentissage.

Justification : C'est le seul moyen de mesurer la capacité de généralisation du modèle. Un score élevé sur le Train mais faible sur le Test indiquerait que le modèle a simplement "appris par cœur" (surapprentissage) au lieu de comprendre les concepts géographiques.

II. Modèle de base (Baseline)

- **Architecture :** Un réseau CNN simple composé de deux couches de convolution suivies d'une couche dense classique (Flatten).
- **Performances initiales :** Accuracy de **83,16 %**.
- **Analyse critique :** Le modèle présente un **surapprentissage (overfitting) précoce**. Les courbes divergent dès l'époque 6 : le modèle mémorise le bruit des données d'entraînement au lieu de généraliser les formes géographiques.

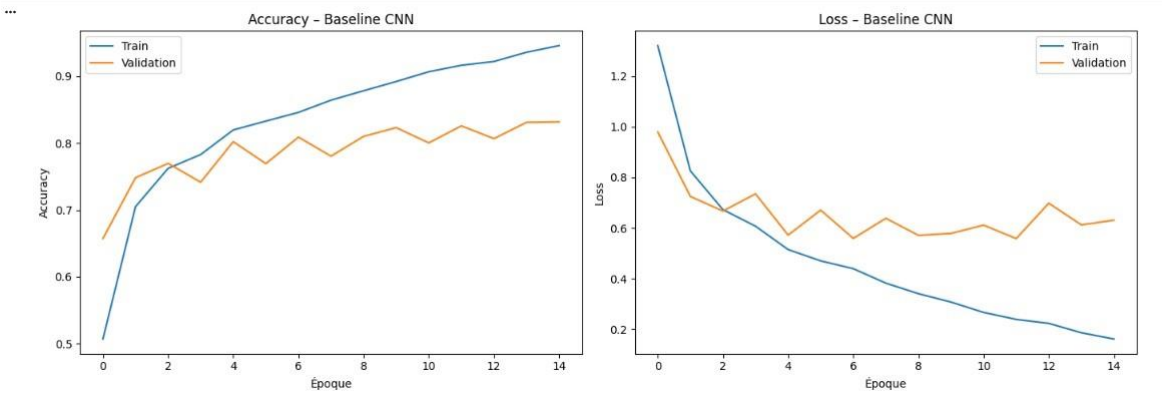


Figure 1 – Courbes d'accuracy et de loss du modèle Baseline CNN

III. Amélioration du modèle (CNN Amélioré)

Pour pallier les faiblesses du Baseline, une architecture plus profonde et robuste a été implémentée.

- **Justification des choix :**
  - **Régularisation (Dropout) :** Utilisation d'un Dropout progressif (0.2 à 0.5) pour forcer le réseau à apprendre des caractéristiques redondantes.
  - **Batch Normalization :** Ajoutée après chaque convolution pour stabiliser le signal et accélérer l'apprentissage.
  - **Global Average Pooling (GAP) :** Remplace le Flatten pour réduire drastiquement le nombre de paramètres et limiter l'overfitting.

- **Résultats :** Accuracy de **95,14 %**. L'amélioration est de **+11,98 points**, avec des courbes d'entraînement et de validation parfaitement synchronisées.

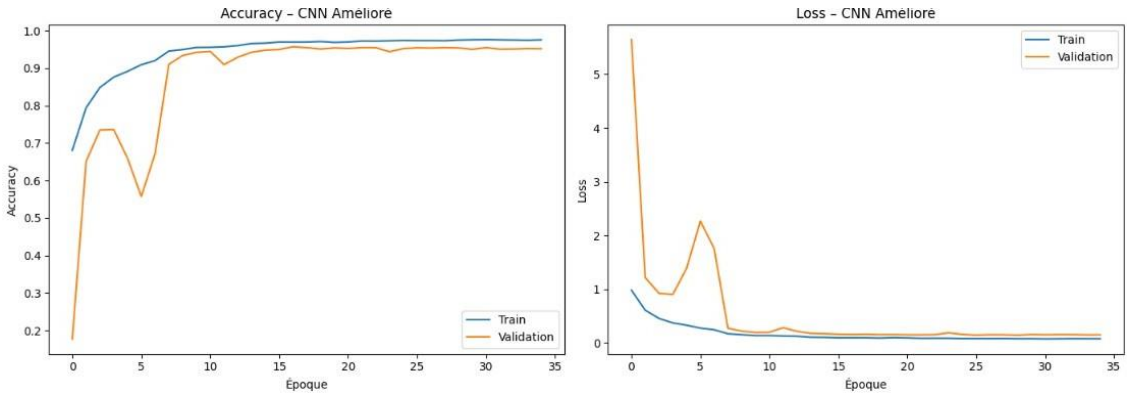


Figure 2 – Courbes d'accuracy et de loss du CNN Amélioré

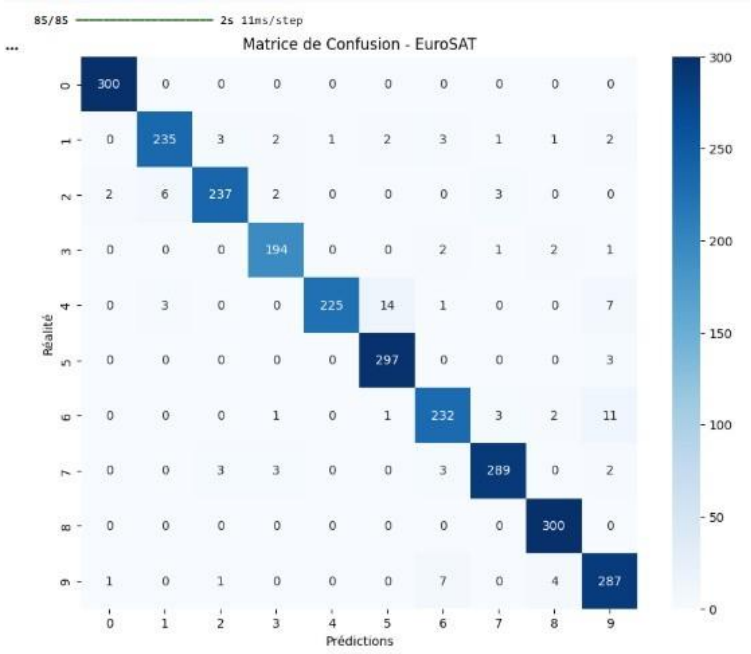


Figure 3 – Matrice de confusion du CNN Amélioré

Cette matrice valide scientifiquement le CNN Amélioré. Avec une telle diagonale, le modèle prouve sa capacité de généralisation. Les erreurs restantes sont marginales et concernent des classes aux caractéristiques visuelles intrinsèquement proches à une résolution de (64×64).

IV. Transfer Learning

- **Modèle utilisé :** ResNet50 pré-entraîné sur ImageNet.
- **Adaptation :** Gel des couches de base et ajout d'une tête de classification personnalisée.
- **Comparaison :** Le Transfer Learning atteint **94,50 %** d'accuracy. Bien que très stable et rapide à entraîner (5 époques contre 35), il est légèrement surpassé par le CNN optimisé "maison" qui semble mieux s'adapter aux spécificités des images EuroSAT de basse résolution.

V. Évaluation et analyse des résultats

- **Analyse des erreurs :** La matrice de confusion révèle des confusions sémantiques réelles :

  - **Industriel vs Forêt :** Les zones industrielles sombres sont confondues avec la canopée forestière à cause de textures similaires à 64×64.
  - **Cultures vs Eau :** Les sols agricoles très irrigués (sombres) sont parfois classés en "SeaLake", le modèle interprétant la faible réflectance comme de l'eau.
- **Classes difficiles :** Les classes aux tons chromatiques proches (ex : Herbaceous Vegetation vs Pasture) restent les plus ardues à distinguer.

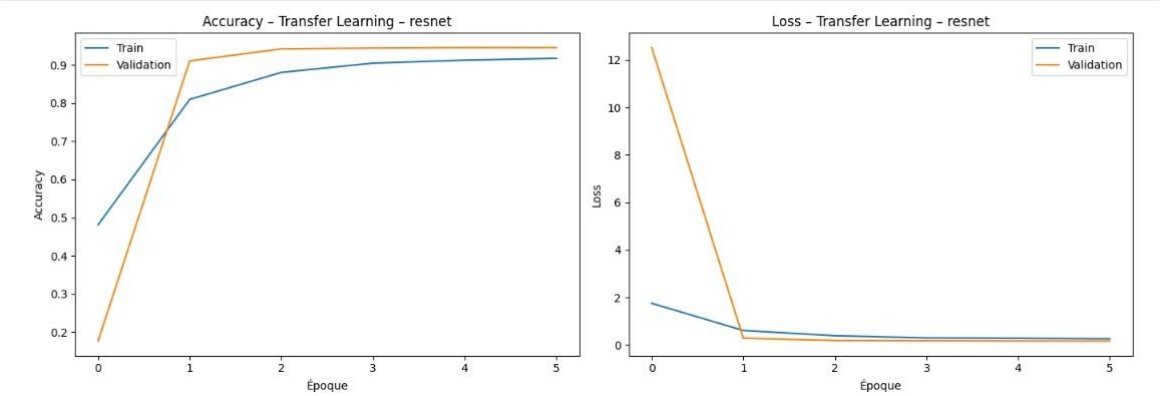


Figure 4 – Courbes comparatives des modèles



Figure 5 – Exemples d'erreurs de classification du modèle

VI. Discussion et conclusion

- **Limites :** La résolution spatiale limitée (64×64) est le principal frein à l'atteinte d'une précision parfaite, car elle lisse les détails structurels (routes, bâtiments).
- **Pistes d'amélioration :**

1. Utilisation de données multispectrales (bandes infrarouges du Sentinel-2) pour mieux séparer la végétation de l'eau.
2. Data Augmentation plus agressive (rotations, zooms) pour varier les perspectives.

- **Conclusion :** Ce projet démontre qu'une architecture personnalisée bien régularisée est capable de rivaliser avec les modèles de pointe (ResNet) pour des tâches de niche comme la télédétection.

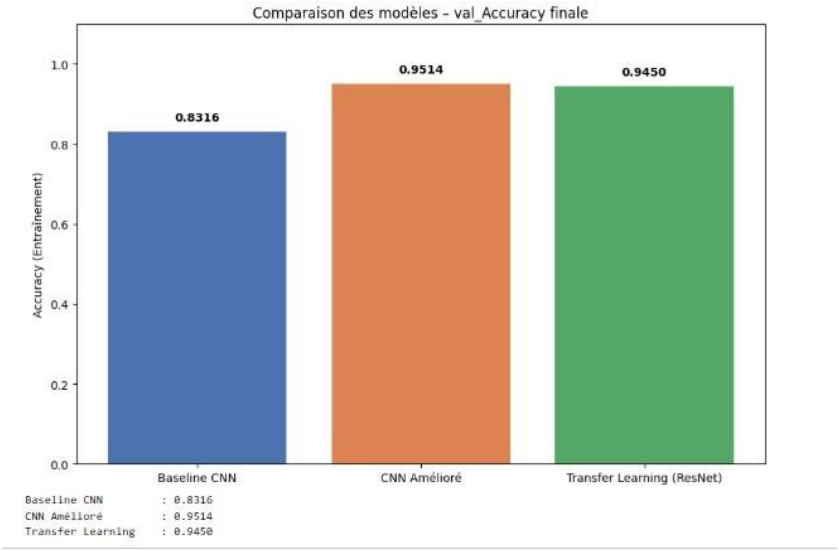


Figure 6 – Synthèse visuelle des résultats

VII. Conclusion générale

Ce projet de classification d'images satellitaires a permis de mettre en lumière l'efficacité des réseaux de neurones convolutionnels pour le traitement de données géographiques complexes.

L'expérimentation a montré qu'un modèle simple (Baseline) est rapidement limité par le phénomène de surapprentissage, atteignant une précision de 83,16 %. L'introduction stratégique de techniques de régularisation comme le Dropout, la Batch Normalization et le remplacement des couches denses par un Global Average Pooling a transformé ces résultats, portant l'accuracy à 95,14 %. Ce score surpasse même les performances obtenues via le Transfer Learning (ResNet50), démontrant qu'une architecture personnalisée, bien que plus longue à entraîner, peut s'avérer plus fine et mieux adaptée aux spécificités d'un dataset de petite résolution comme EuroSAT.

Malgré ces excellents résultats, l'analyse des erreurs souligne les limites intrinsèques liées à la résolution de 64×64 pixels. Les confusions entre zones industrielles et forêts, ou entre cultures irriguées et plans d'eau, rappellent que la signature visuelle RGB ne suffit pas toujours à lever toutes les ambiguïtés sémantiques.

En perspective, l'ajout de bandes spectrales supplémentaires (infrarouge) ou l'utilisation de mécanismes d'attention (Transformers) pourraient constituer des pistes prometteuses pour atteindre une précision quasi-totale. En conclusion, ce travail valide la viabilité des CNN pour l'aide à la décision en télédétection et pose les bases d'un système de surveillance automatisé du territoire.