Dakar Institute of Technology (DIT)

Département Data Science & Intelligence Artificielle

Certification en Data Science

RAPPORT DE PROJET FINAL – DEEP LEARNIN

Certification data Science cohorte 2

Projet 2 : Classification d'images satellitaires

Approche par CNN, Régularisation et Transfer Learning (VGG16)

- **Groupe 4***:*

  Cheikh Yakhouba CISSÉ

  Souleymane GUEYE

  Ndeye Fatou NDIAYE

  Ndeye Khady NDIAYE

- Sous l'encadrement de :

  Professeur **Rose Bandolo**

Dataset : *EuroSAT – Images satellitaires RGB (10 classes, 64×64 pixels)*

I. Exploration et préparation des données

1.1 Structure du dataset

Le dataset **EuroSAT** utilisé dans ce projet est constitué d'images satellitaires RGB de taille homogène 64×64 pixels, réparties en 10 classes de terrain. Les fichiers CSV fournis permettent une séparation directe en trois ensembles distincts.

Ensemble	Nombre d'images	Usage
Train	18 900	Entraînement
Validation	5 400	Suivi de l'entraînement
Test	2 700	Évaluation finale
Total	**27 000**	–

1.2 Classes du dataset

Les 10 classes de terrain présentes dans le dataset sont les suivantes : AnnualCrop, Forest, HerbaceousVegetation, Highway, Industrial, Pasture, PermanentCrop, Residential, River et SeaLake. La répartition entre les classes est équilibrée, avec environ 2 700 images par classe, ce qui est favorable à l'entraînement sans nécessiter de techniques spéciales de rééquilibrage.

1.3 Stratégie de prétraitement

Normalisation : les valeurs des pixels sont ramenées entre 0 et 1 en divisant par 255.

Redimensionnement : les images conservent leur taille native de 64×64 pixels.

Séparation : les CSV fournis par le dataset sont utilisés directement pour définir les ensembles train, validation et test.

Construction des chemins : les noms de fichiers contenus dans la colonne Filename incluent déjà le sous-dossier de classe (ex. AnnualCrop/AnnualCrop_142.jpg), ce qui permet de reconstruire les chemins complets vers chaque image.

II. Modèle de base (Baseline CNN)

2.1 Architecture

Un réseau de neurones convolutionnel simple a été construit from scratch pour établir une référence de performance. L'architecture comporte trois blocs convolutionnels successifs, chacun composé d'une couche Conv2D suivie d'un MaxPooling2D, puis une couche Dense de 256 neurones et une couche de sortie Softmax à 10 classes.

Couche	Paramètres
Conv2D (32 filtres, 3×3, ReLU)	Padding same
MaxPooling2D (2×2)	–
Conv2D (64 filtres, 3×3, ReLU)	Padding same
MaxPooling2D (2×2)	–
Conv2D (128 filtres, 3×3, ReLU)	Padding same
MaxPooling2D (2×2)	–
Dense (256, ReLU)	–
Dense (10, Softmax)	Sortie – 10 classes

2.2 Résultats

Le modèle a été entraîné sur 20 époques avec l'optimiseur Adam et la fonction de perte categorical_crossentropy. Les performances obtenues sur le jeu de test sont les suivantes :

Loss test : 0.7277

Accuracy test : 85.30 %

L'analyse des courbes d'apprentissage révèle un écart croissant entre l'accuracy d'entraînement et celle de validation, signe d'un overfitting modéré. Ce constat justifie les améliorations apportées dans la section suivante.

III. Amélioration du modèle

3.1 Améliorations appliquées

Deux améliorations complémentaires ont été implémentées afin de réduire l'overfitting et améliorer la généralisation du modèle :

Amélioration 1 – Data Augmentation : des transformations aléatoires sont appliquées aux images d'entraînement afin d'augmenter artificiellement la diversité du dataset et de rendre le modèle plus robuste. Les transformations appliquées sont : rotation (±20°), décalage horizontal et vertical (10 %), flip horizontal et zoom (10 %).

Amélioration 2 – Dropout et Batch Normalization : une couche de Batch Normalization est ajoutée après chaque bloc convolutionnel pour stabiliser l'entraînement et accélérer la convergence. Des couches Dropout (taux de 25 % après chaque bloc convolutionnel, 50 % avant la couche de sortie) sont ajoutées pour réduire la co-adaptation des neurones et limiter l'overfitting.

Des callbacks EarlyStopping (patience = 5) et ReduceLROnPlateau (facteur 0.5, patience = 3) ont également été mis en place pour éviter le surapprentissage et optimiser le taux d'apprentissage.

3.2 Résultats

Loss test : 0.3109

Accuracy test : 89.48 %

Gain par rapport au baseline : +4.18 points de pourcentage

L'ajout du Dropout et de la Batch Normalization combinés à la Data Augmentation réduit significativement l'overfitting. Les courbes de validation sont plus stables et l'écart avec les courbes d'entraînement est nettement réduit.

IV. Transfer Learning (VGG16)

4.1 Justification du choix

Le modèle VGG16 pré-entraîné sur ImageNet a été sélectionné pour cette étape. Ce choix est motivé par plusieurs raisons : VGG16 est un modèle bien documenté, aux performances éprouvées sur les tâches de classification d'images, et sa simplicité architecturale facilite l'adaptation. Les représentations apprises sur ImageNet (contours, textures, formes) sont suffisamment générales pour être transférées à des images satellitaires.

4.2 Architecture et stratégie

La stratégie adoptée est le feature extraction : les couches convolutionnelles de VGG16 sont gelées (non entraînables) et seule une nouvelle tête de classification est ajoutée et entraînée. La tête comprend une couche GlobalAveragePooling2D, une couche Dense de 256 neurones avec ReLU, un Dropout à 50 %, et une couche de sortie Softmax à 10 classes. L'optimiseur Adam est utilisé avec un taux d'apprentissage réduit (1e-4) pour ne pas perturber les poids pré-entraînés.

Le prétraitement des images est adapté à VGG16 en utilisant la fonction preprocess_input de Keras, qui normalise les images selon les statistiques ImageNet.

4.3 Résultats

Loss test : À compléter après exécution

Accuracy test : 91.67 %

Gain par rapport au CNN Amélioré : +2.19 points de pourcentage

Le Transfer Learning avec VGG16 converge nettement plus rapidement que les CNN entraînés from scratch, en atteignant de meilleures performances dès les premières époques. Cela confirme l'intérêt du Transfer Learning même lorsqu'il existe un écart de domaine entre les données source (ImageNet) et les données cibles (images satellitaires).

V. Évaluation et analyse des résultats

5.1 Comparaison des modèles

Modèle	Loss (Test)	Accuracy (Test)	Gain
Baseline CNN	0.7277	85.30 %	–
CNN Amélioré	0.3109	89.48 %	+4.18 %
Transfer Learning (VGG16)	–	**91.67 %**	+2.19 %

5.2 Analyse de la matrice de confusion

L'analyse de la matrice de confusion du modèle final (VGG16) met en évidence les observations suivantes :

- Les classes présentant des signatures visuelles très distinctes comme SeaLake et River sont les mieux classifiées, avec des taux de reconnaissance élevés.
- Les confusions les plus fréquentes s'observent entre Forest et HerbaceousVegetation, deux classes partageant des textures végétales similaires difficiles à distinguer à 64×64 pixels.
- Les classes Residential et Industrial génèrent également des confusions, leurs structures bâties présentant des caractéristiques visuelles proches.
- Les classes agricoles AnnualCrop et PermanentCrop sont parfois confondues en raison de leur apparence saisonnière similaire.

5.3 Analyse par classe

Le rapport de classification détaillé confirme que les meilleures performances sont obtenues sur les classes à fort contraste visuel (SeaLake, Highway, River), tandis que les classes végétales et bâties restent les plus difficiles à distinguer. Ces résultats sont cohérents avec la nature des images satellitaires à basse résolution (64×64 pixels), qui limite la granularité des détails disponibles pour la classification.

VI. Discussion et conclusion

6.1 Synthèse des résultats

Ce projet a permis de mettre en place une pipeline complète de classification d'images satellitaires sur le dataset EuroSAT. Les trois modèles développés montrent une progression cohérente et mesurable des performances : le Baseline CNN établit une référence solide à 85.30 %, le CNN Amélioré réduit l'overfitting et monte à 89.48 %, et le Transfer Learning avec VGG16 atteint 91.67 %, confirmant l'apport significatif des représentations pré-apprises.

6.2 Limites du modèle

- La résolution de 64×64 pixels constitue la principale limitation : elle ne permet pas de capturer des détails fins indispensables à la distinction de classes visuellement proches.
- VGG16 a été pré-entraîné sur des photographies naturelles (ImageNet) et non sur des images satellitaires, ce qui représente un écart de domaine pouvant limiter le transfert de certaines représentations.
- L'absence de GPU lors de l'exécution a contraint le nombre d'époques et allongé les temps d'entraînement, ce qui peut légèrement affecter la convergence optimale des modèles.
- Le fine-tuning des dernières couches de VGG16 n'a pas été réalisé et pourrait permettre d'améliorer encore les performances.

6.3 Pistes d'amélioration

- Fine-tuning : dégeler les dernières couches de VGG16 et les réentraîner à un taux d'apprentissage très faible pour affiner les représentations sur les données satellitaires.
- ResNet50 : tester une architecture plus profonde avec connexions résiduelles, potentiellement plus performante sur ce type de données.
- Augmentation adaptée : appliquer des rotations à 90° et 180° particulièrement pertinentes pour les images satellitaires, insensibles à l'orientation.
- Modèles spécialisés : explorer des modèles pré-entraînés sur des données de télédétection comme BigEarthNet ou SEN12MS, dont le domaine source est plus proche de celui du dataset EuroSAT.

- Résolution supérieure : utiliser la version EuroSAT à haute résolution (64×64 en RGB multispectrales) ou des images de plus grande taille pour enrichir l'information disponible.

Conclusion :

Ce projet illustre l'efficacité croissante des approches de Deep Learning pour la classification d'images satellitaires. La progression observée de 85.30 % à 91.67 % entre le CNN de base et le Transfer Learning avec VGG16 démontre l'importance du choix architectural et des techniques de régularisation. Ces résultats constituent une base solide pour des applications réelles de surveillance environnementale et d'analyse du territoire.

NB : Veuillez exécuter le noteBook svp pour voir les schémas et les interprétations.